Fraud Detection

Detección de fraude en transacciones con tarjeta

1. Contexto de Negocio

El objetivo es detectar transacciones fraudulentas con tarjeta de crédito. Solo 492 de 284,807 operaciones son fraude (0.1727%, ratio 1:577), por lo que la exactitud (accuracy) no sirve como métrica: un modelo que siempre dijera 'legítima' acertaría el 99.83% sin detectar ningún fraude. Se usa AUC-PR, precision y recall.

2. Dataset

Campo	Valor
Fuente	Credit Card Fraud Detection — Kaggle
Registros	284,807 transacciones (48 horas)
Variables	Time, Amount, V1-V28 (PCA) y Class
Fraudes	492 (0.1727%)
Ratio desbalanceo	1:577

3. Hallazgos del Análisis Exploratorio

Los fraudes se concentran de madrugada: a las 2h la tasa llega al 1.71%. Además suelen ser de importe pequeño: la mediana es de 9.25 € frente a 22.00 € en las legítimas, coherente con el testeo de tarjetas robadas. Los componentes V4, V14, V3 y V17 son los que mejor separan las clases.

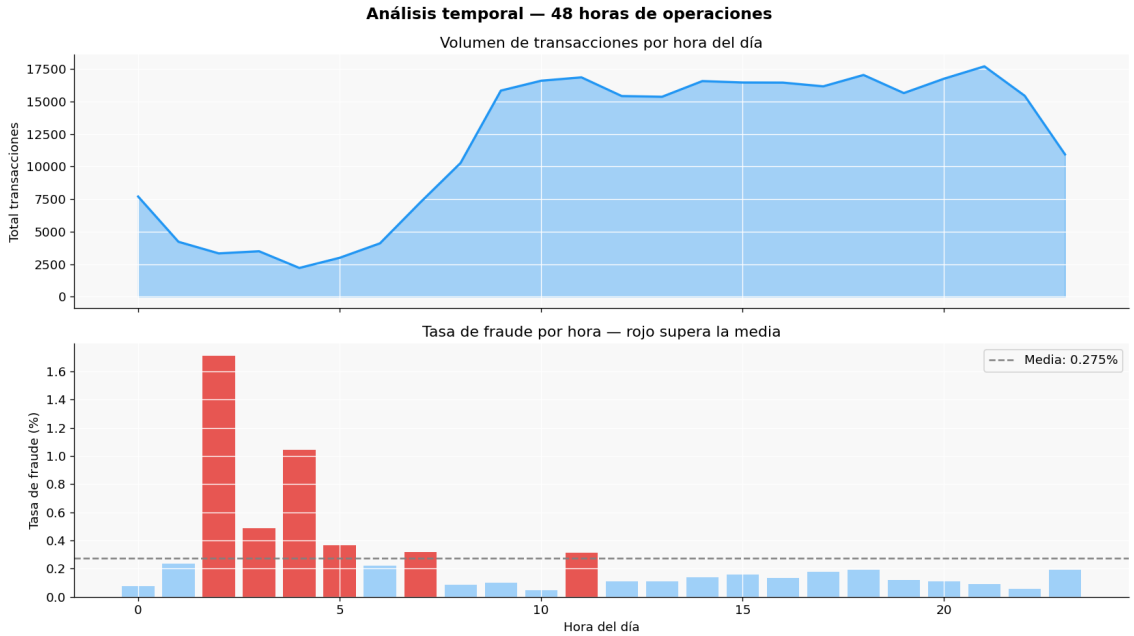


Figura 1 — Volumen y tasa de fraude por hora del día

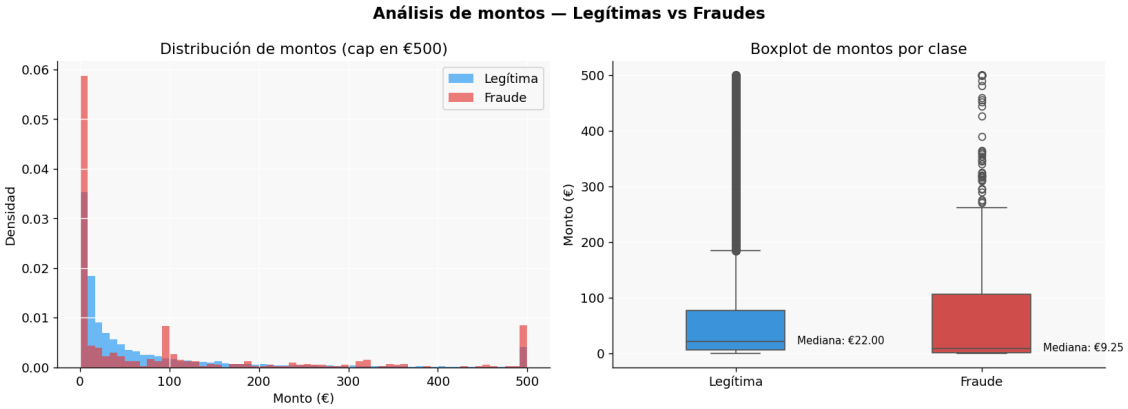


Figura 2 — Distribución de montos: legítimas frente a fraudes

4. Metodología del Modelo

Se aplicó SMOTE solo sobre el conjunto de entrenamiento (fraudes al 10%) y se compararon LightGBM y XGBoost. La evaluación se hizo sobre un test sin modificar (20%, con 98 fraudes) y el umbral de decisión se optimizó en lugar de usar 0.5.

Etapa	Técnica	Herramienta
Desbalanceo	SMOTE (solo en train)	imbalanced-learn
Modelos	LightGBM y XGBoost	lightgbm, xgboost
Métrica principal	AUC-PR	scikit-learn
Umbral	Optimizado por F1 (0.9747)	scikit-learn
Explicabilidad	SHAP	shap

5. Resultados del Modelo

Métrica (umbral 0.5)	XGBoost	LightGBM
AUC-PR	0.8538	0.8659
AUC-ROC	0.9854	0.9795
F1-Score	0.4656	0.7311

Se eligió LightGBM por ganar en AUC-PR y en F1. Con el umbral optimizado (0.9747), el modelo final detecta 80 de 98 fraudes con 4 falsas alarmas.

Modelo final: LightGBM	Valor
Precision	0.9524
Recall	0.8163
F1-Score	0.8791

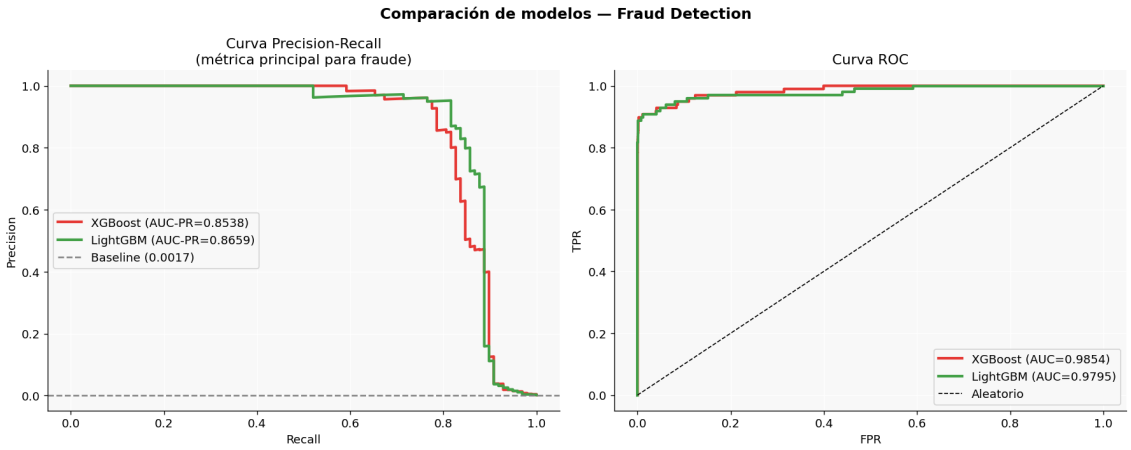


Figura 3 — Curvas Precision-Recall y ROC

6. Impacto Económico y Explicabilidad

Concepto (test set)	Valor
Fraude detectado	7,901.31 €
Fraude no detectado	2,746.62 €
Valor protegido	74.2%

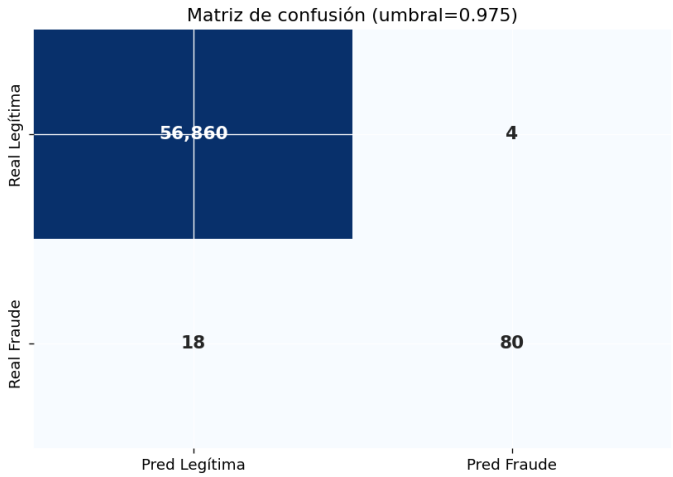


Figura 4 — Matriz de confusión (umbral 0.975)

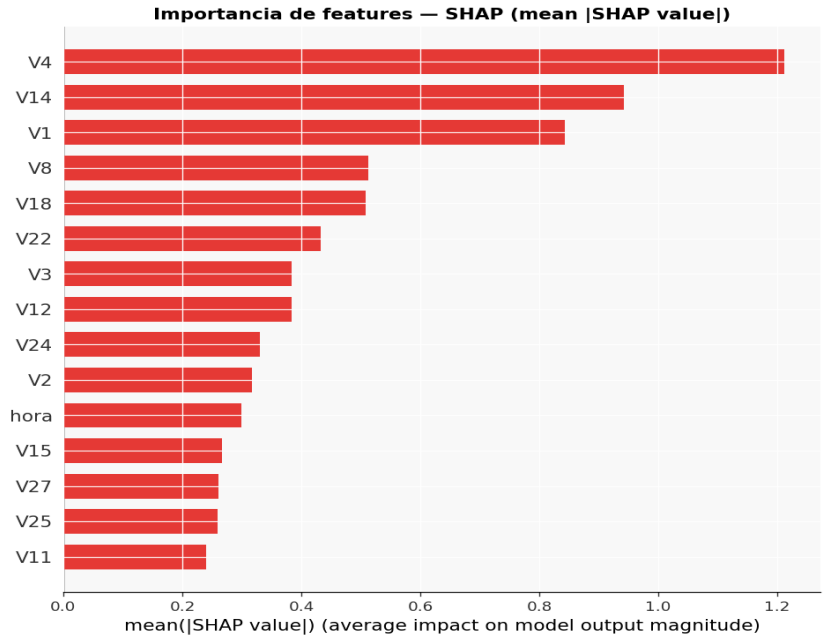


Figura 5 — Importancia de variables según SHAP

7. Conclusiones

LightGBM con SMOTE detecta el 82% de los fraudes del test con una precision del 95%, es decir, casi todas las alertas son fraudes reales. V4 y V14 son las variables que más influyen en las decisiones del modelo, y la hora de la transacción también aporta señal.

8. Limitaciones

• El umbral se eligió sobre el mismo test que se usó para evaluar, por lo que las métricas finales son algo optimistas. Lo correcto sería usar un conjunto de validación aparte.

• El test solo contiene 98 fraudes, así que el recall tiene un margen de error amplio: un fraude más o menos cambia varios puntos.

• Los datos son de 2013 y las variables V1-V28 son anónimas, por lo que no se pueden interpretar en términos de negocio.

9. Stack Tecnológico

Herramienta	Uso
Python 3.10	Lenguaje principal
Pandas / NumPy	Manipulación de datos
DuckDB	SQL analítico en local
LightGBM / XGBoost	Modelos de clasificación
imbalanced-learn	SMOTE
SHAP	Explicabilidad
Power BI	Dashboard ejecutivo